Трансформерные модели.

Алексей Андреевич Сорокин

МГУ им. М. В. Ломоносова
весенний семестр 2022–2023 учебного года
Межфакультетский курс “Введение в компьютерную лингвистику” 5 апреля, занятие 7

Механизм внимания: переобозначение

- Текущая формула (переобозначения):

$$
\begin{aligned}
h &= \sum_i \alpha_i h_i^{value}, \\
\alpha_i &\sim \exp\left(\langle h_i^{key}, s\rangle\right), \\
s &- \text{глобальный вектор “запроса” (query)}, \\
h_i^{value} &- \text{“эмбеддинг-значение” (value)}, \\
h_i^{key} &- \text{“эмбеддинг-ключ” (key)}.
\end{aligned}
$$

- Откуда взять h_i^{value}, h_i^{key}.

Механизм внимания: переобозначение

- Текущая формула (переобозначения):

$$
\begin{aligned}
h &= \sum_i \alpha_i h_i^{value}, \\
\alpha_i &\sim \exp\left(\langle h_i^{key}, s\rangle\right), \\
s &- \text{глобальный вектор “запроса” (query)}, \\
h_i^{value} &- \text{“эмбеддинг-значение” (value)}, \\
h_i^{key} &- \text{“эмбеддинг-ключ” (key)}.
\end{aligned}
$$

- Откуда взять h_i^{value}, h_i^{key}.
- Проще всего вставить один слой персептрона:

$$
\begin{aligned}
h_i^{value} &= g(W^{value} h_i), \\
h_i^{key} &= g(W^{key} h_i)
\end{aligned}
$$

Механизм внимания: матричный вид

- Всё можно переписать в матричном виде:

$$\begin{aligned} h &= A_{1\times L} V_{L\times d}, \\ A &= \mathrm{softmax}(q_{1\times d} K^T_{L\times d}), \\ V &= g(H_{L\times d} W^{value}_{d\times d}), \\ K &= g(H_{L\times d} W^{key}_{d\times d}) \end{aligned}$$

- Финальная формула:

$$h = \mathrm{softmax}(QK^T)V$$

Механизм внимания: матричный вид

- Всё можно переписать в матричном виде:

$$\begin{aligned} h &= A_{1\times L} V_{L\times d}, \\ A &= \mathrm{softmax}(q_{1\times d} K^T_{L\times d}), \\ V &= g(H_{L\times d} W^{value}_{d\times d}), \\ K &= g(H_{L\times d} W^{key}_{d\times d}) \end{aligned}$$

- Финальная формула:

$$h = \mathrm{softmax}(QK^T)V$$

- На практике добавляют нормализующий множитель:

$$h = \mathrm{softmax}(\frac{QK^T}{\sqrt{d}})V$$

- Без него обучение более нестабильное.

Механизм самовнимания : матричный вид

- Механизм внимания используется, чтобы посчитать состояние для всего предложения с учётом всех слов.
- А что если так же считать новые состояния для всех слов?
- В этом случае даже удалённые слова будут влиять на текущий вектор (проблема для рекуррентных сетей).

Механизм самовнимания : матричный вид

- Механизм внимания используется, чтобы посчитать состояние для всего предложения с учётом всех слов.
- А что если так же считать новые состояния для всех слов?
- В этом случае даже удалённые слова будут влиять на текущий вектор (проблема для рекуррентных сетей).
- Достаточно сделать "запрос" Q матрицей:

$$Q_{L\times d} = g(H_{L\times d} W^{query}_{d\times d})$$

- В итоге получаем:

$$\begin{aligned} H' &= A_{L\times L} V_{L\times d}, \\ A &= \mathrm{softmax}(Q_{L\times d} K^T_{L\times d}), \\ Q &= g(H_{L\times d} W^{query}_{d\times d}), \\ V &= g(H_{L\times d} W^{value}_{d\times d}), \\ K &= g(H_{L\times d} W^{key}_{d\times d}) \end{aligned}$$

Механизм самовнимания: иллюстрация

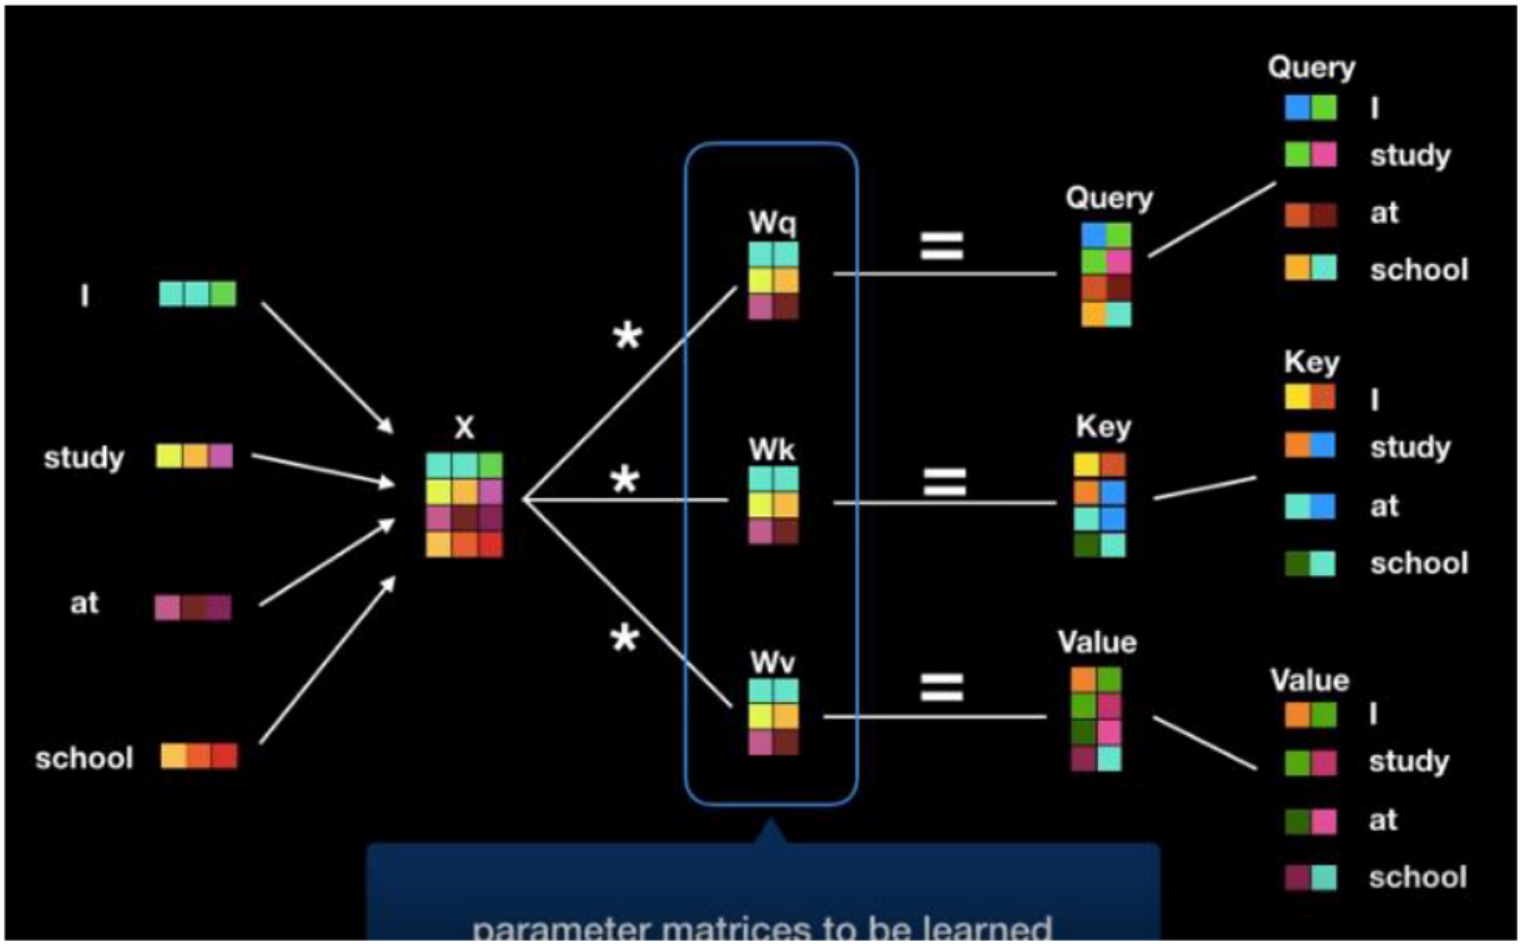

Механизм самовнимания: иллюстрация

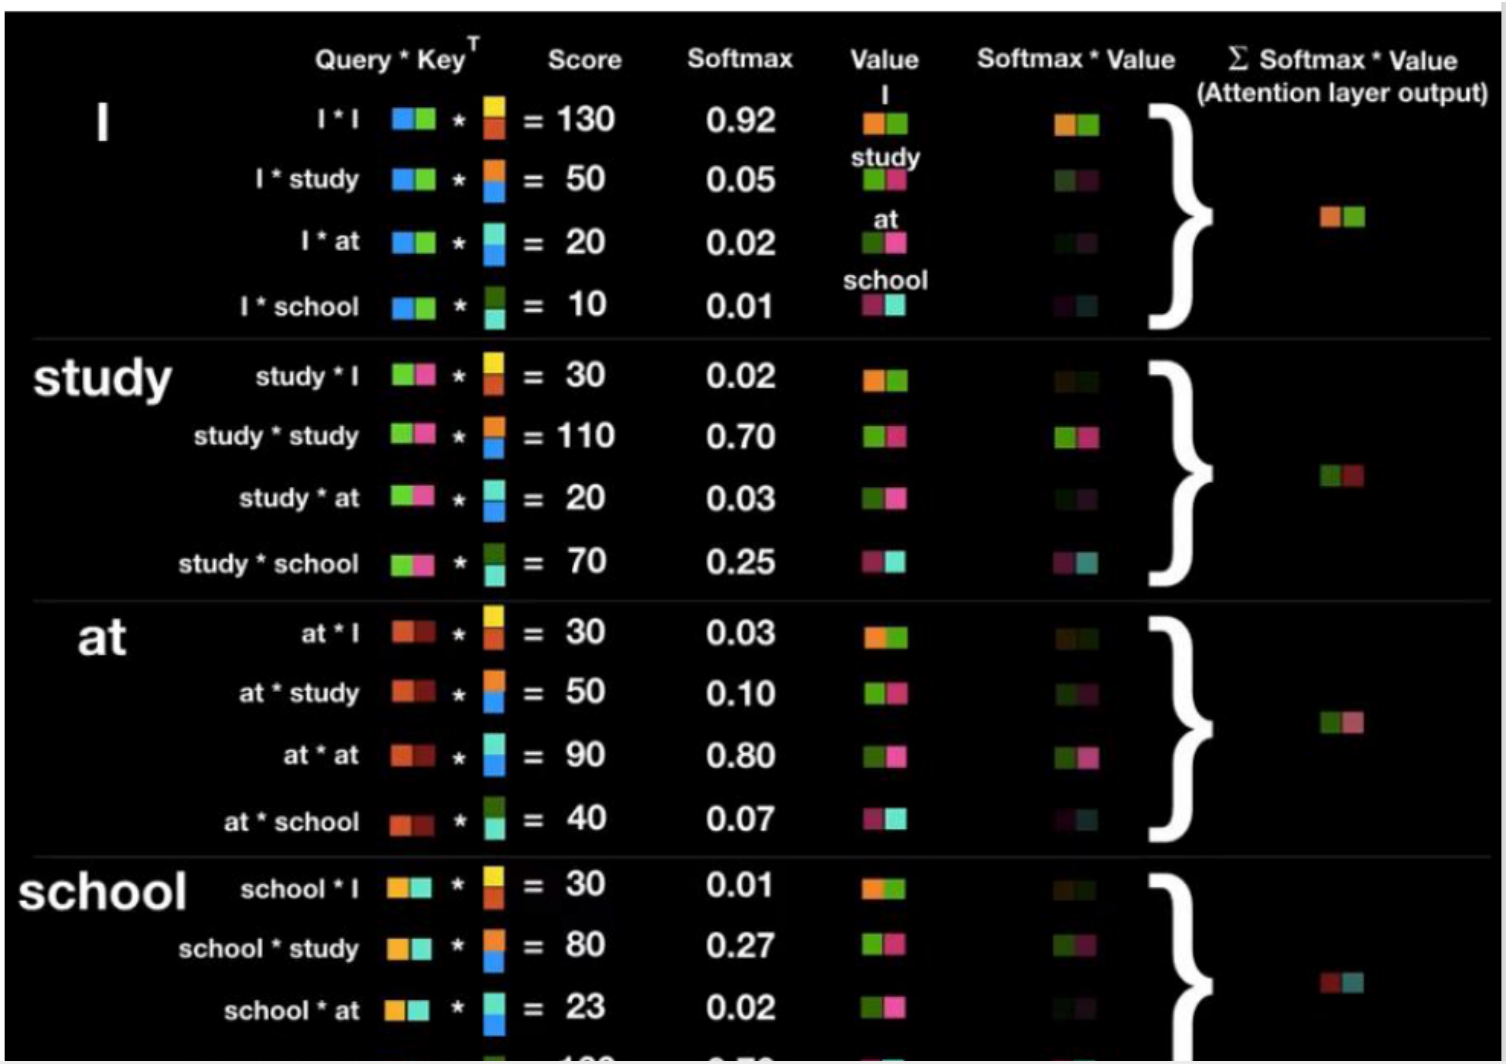

Механизм самовнимания: трансформеры

- Механизм внимания – это один слой трансформерной архитектуры.
- Между такими слоями вставляются residual-переходыполносвязные подслои и слой-нормализация (LayerNorm). Параллельно с трансформерным блоком вставляется residual-переход.

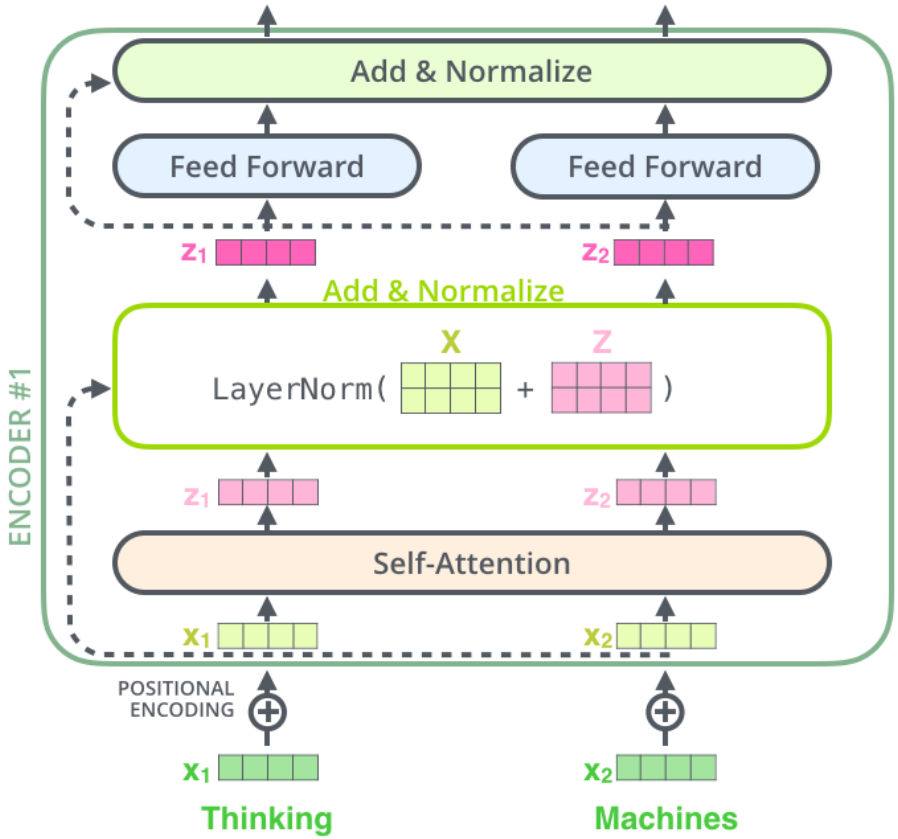

Механизм самовнимания: множественное внимание

- Может возникнуть потребность проявлять внимание с точки зрения разных аспектов и к разным словам.

Вася съел большую банку варенья.

банку $\rightarrow$ большую	морфология
банку $\rightarrow$ съел	семантика

Механизм самовнимания: множественное внимание

- Может возникнуть потребность проявлять внимание с точки зрения разных аспектов и к разным словам.

Вася съел большую банку варенья.

банку $\to$ большую морфология

банку $\to$ съел семантика

- Это делается с помощью множественного внимания (multi-head attention):

$$\begin{aligned} H'_i &= \mathrm{Attention}(HW_{q,i}, HW_{k,i}, HW_{v,i}) \\ H' &= \mathrm{Concat}(H'_1, \ldots, H'_m) \\ W_{\star,i} &\in \mathbb{R}^{D \times \frac{D}{m}} \end{aligned}$$

- Все эти операции можно делать параллельно.

Механизм самовнимания: множественное внимание

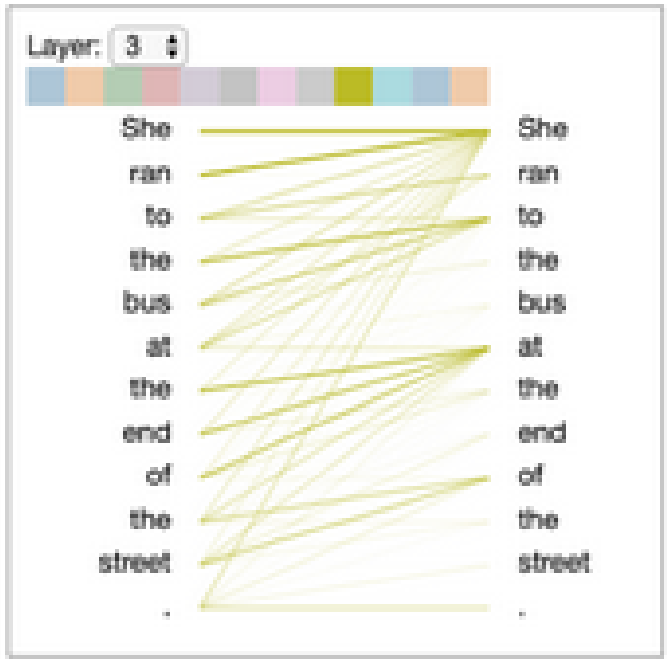

Механизм самовнимания: энкодер-декодер

- В энкодере механизм внимания нужен, чтобы пересчитывать состояния модели, кодирующие исходное предложение.
- В декодере нужно учитывать не только исходное предложение, но и сгенерированную часть результата.

Механизм самовнимания: энкодер-декодер

- В энкодере механизм внимания нужен, чтобы пересчитывать состояния модели, кодирующие исходное предложение.
- В декодере нужно учитывать не только исходное предложение, но и сгенерированную часть результата.
- Как следствие, есть два подслоя внимания:
  - Внимание состояний энкодера к состояниям декодера α_{ij}:

$$i \quad - \quad \text{позиция в генерируемом тексте,}$$
$$j \quad - \quad \text{позиция в исходном тексте.}$$

Механизм самовнимания: энкодер-декодер

- В энкодере механизм внимания нужен, чтобы пересчитывать состояния модели, кодирующие исходное предложение.
- В декодере нужно учитывать не только исходное предложение, но и сгенерированную часть результата.
- Как следствие, есть два подслоя внимания:
  - Внимание состояний энкодера к состояниям декодера α_{ij}:

    i – позиция в генерируемом тексте,
    j – позиция в исходном тексте.
  - Внимание состояний энкодера к состояниям декодера β_{ij}:

    i – позиция в генерируемом тексте,
    j – позиция в генерируемом тексте, $j < i$.
  - При обучении считается $\beta_{ij} = 0$ при $j \geqslant i$, чтобы модель не заглядывала в будущее.

Трансформеры: энкодер-декодер

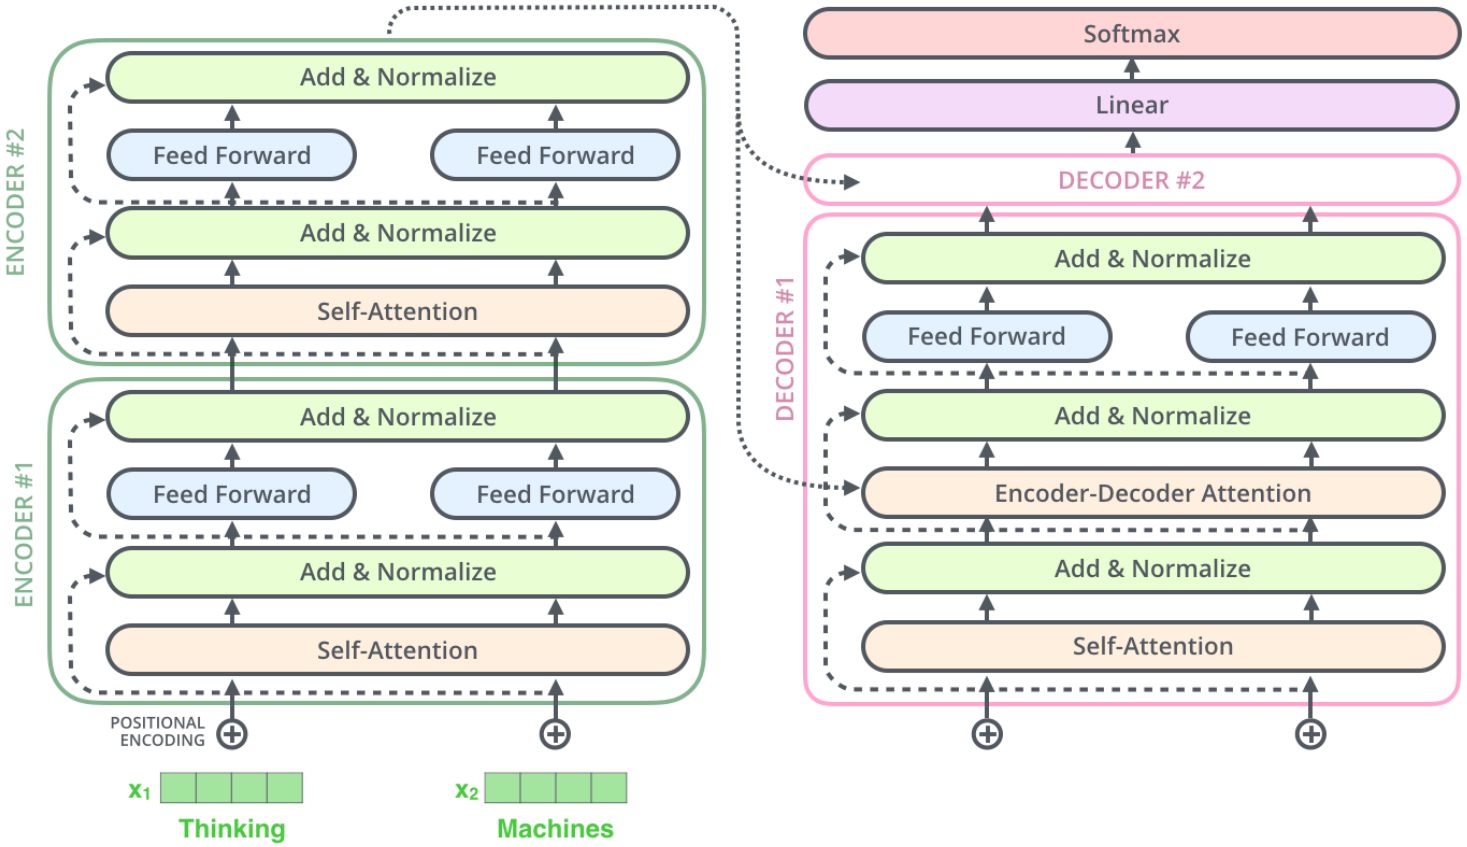

Трансформеры: скорость

- Скорость передачи информации на m шагов:
  - Свёрточные сети: $O(\frac{m}{w})$.
  - Рекуррентные сети: $O(m)$.
  - Трансформеры: $O(1)$.
- Затраты памяти на последовательность длины L:
  - Свёрточные сети: $O(wd^2L)$.
  - Рекуррентные сети: $O(d^2L)$.
  - Трансформеры: $O(L^2d)$.

Трансформеры: позиционное кодирование

- Пока механизм внимания никак не различает одинаковые вектора, стоящие в разных местах.
- Чтобы это исправить, конкатенируют вектора слов с позиционными эмбеддингами:

$$x_i = [emb(word_i), x_{pos}(i)]$$

Трансформеры: позиционное кодирование

- Пока механизм внимания никак не различает одинаковые вектора, стоящие в разных местах.
- Чтобы это исправить, конкатенируют вектора слов с позиционными эмбеддингами:

$$x_i = [emb(word_i), x_{pos}(i)]$$

- x_{pos} иногда задают явно (Vaswani et al., 2017):

$$\begin{aligned} (x_{pos}(i))_{2j} &= \sin \frac{i}{10000^{j/d}}, \\ (x_{pos}(i))_{2j+1} &= \cos \frac{i}{10000^{j/d}}. \end{aligned}$$

- В более поздних подходах их сделали обучаемыми:
  - Это дополнительная матрица размера max_length $\times$ d.
  - Последовательности длиннее max_length не обрабатываются.

Нейронные сети: предобучение на языковом моделировании

- Задача языкового моделирования – предсказание следующего слова в тексте (распределения вероятностей следующего слова).

Я вчера ел вкусную ?

Нейронные сети: предобучение на языковом моделировании

- Задача языкового моделирования – предсказание следующего слова в тексте (распределения вероятностей следующего слова).

Я вчера ел вкусную ?

- Она требует больших знаний о языке:
  - Морфология (если следующее слово существительное, то женского рода).
  - Графика (следующее слово с большой вероятностью кончается на -у).
  - Синтаксис.
  - Семантика (следующее слово “съедобное”).

Нейронные сети: предобучение на языковом моделировании

- Задача языкового моделирования – предсказание следующего слова в тексте (распределения вероятностей следующего слова).

  Я вчера ел вкусную ?

- Она требует больших знаний о языке:
  - Морфология (если следующее слово существительное, то женского рода).
  - Графика (следующее слово с большой вероятностью кончается на -у).
  - Синтаксис.
  - Семантика (следующее слово “съедобное”).
- Кроме того, для получения этой информации не нужны размеченные данные.

Нейронные сети: BERT

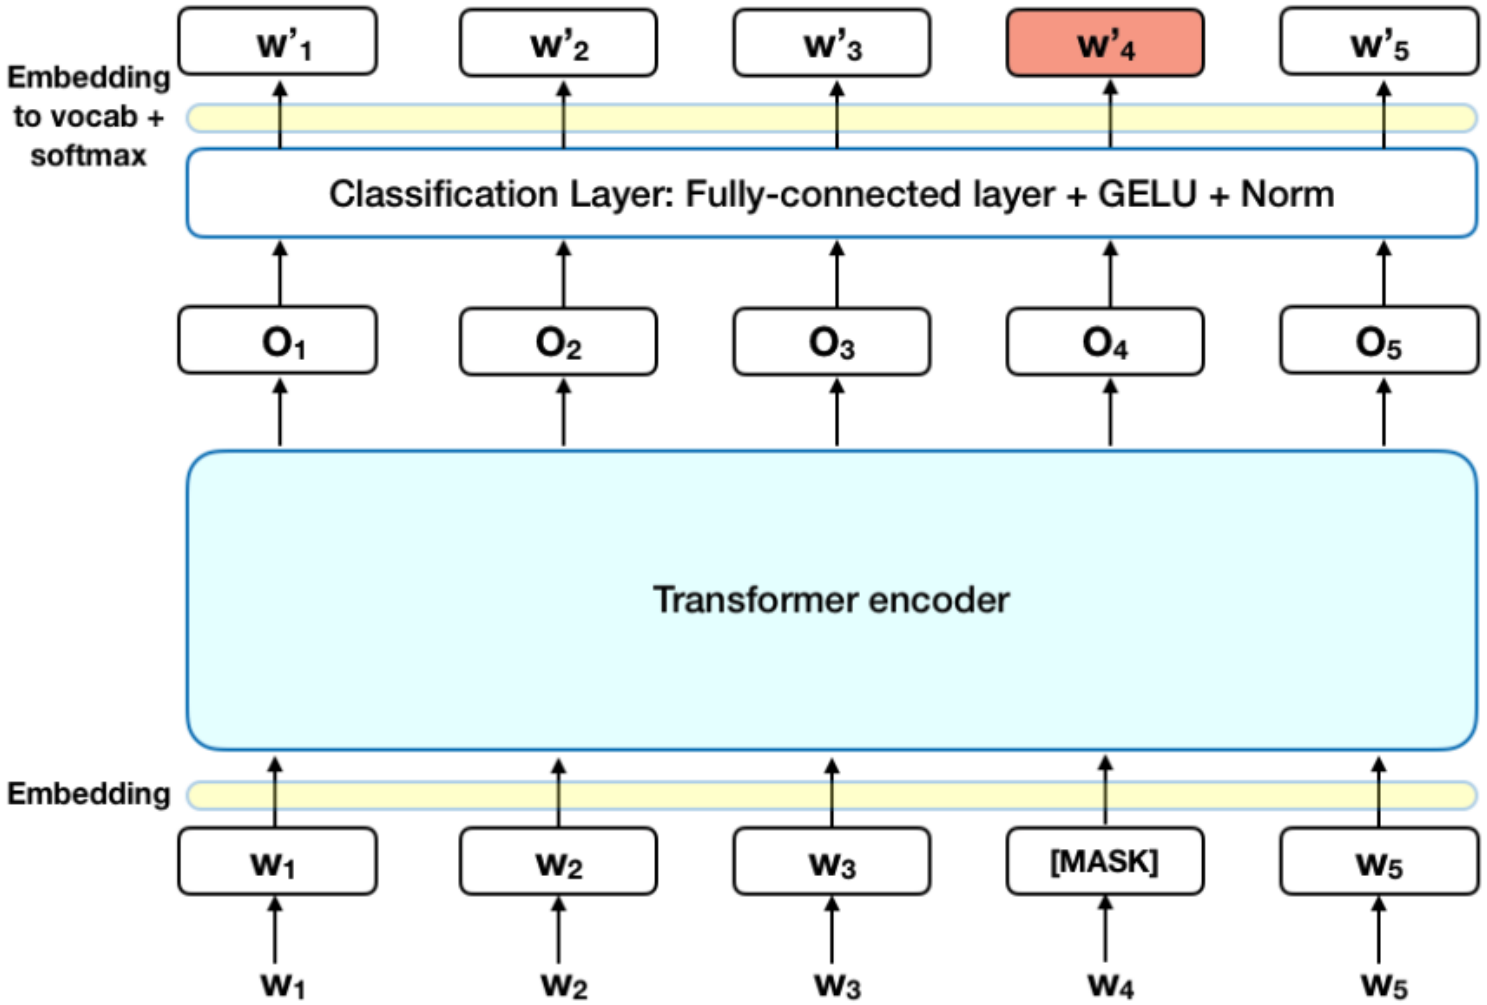

BERT: иллюстрация

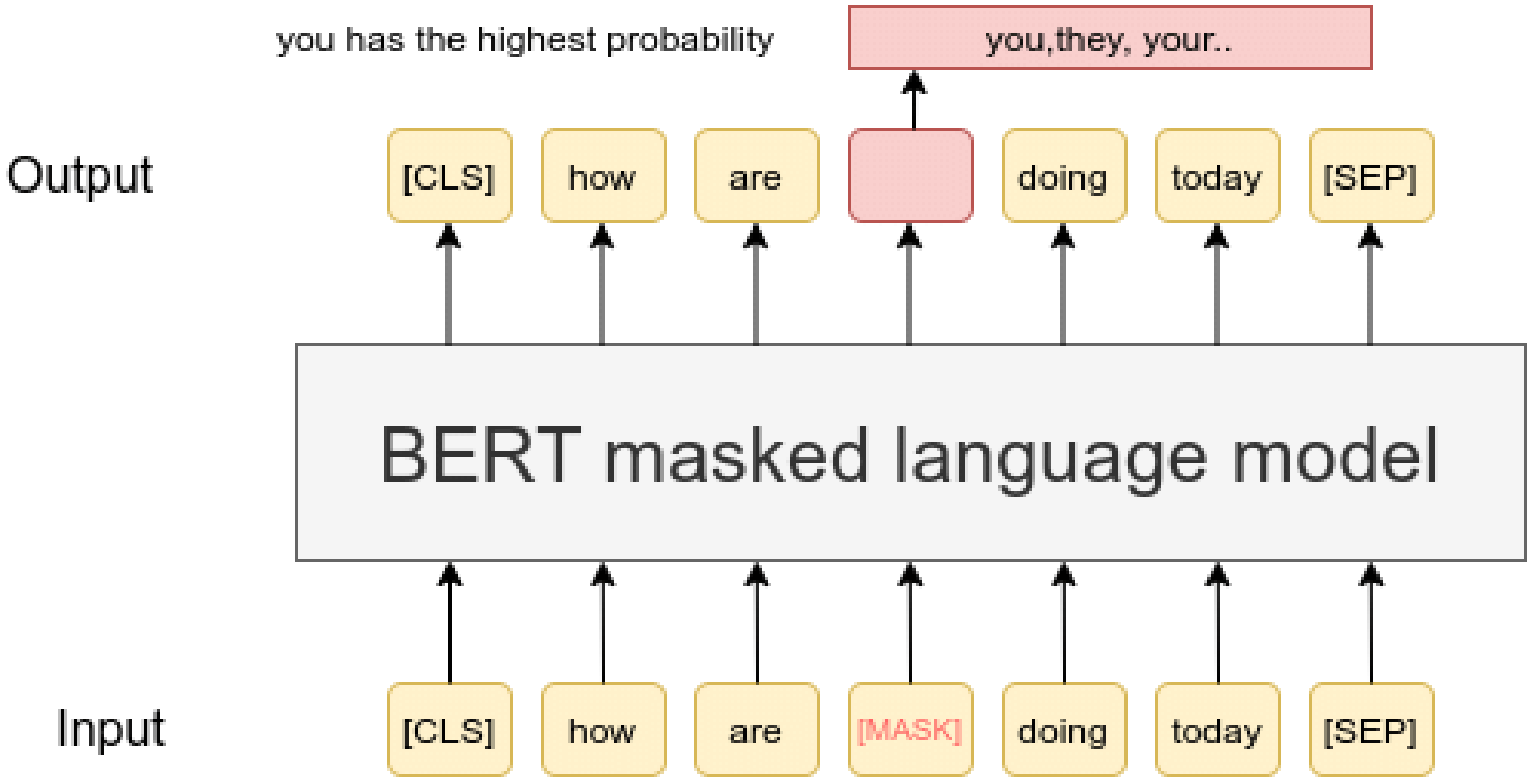

Нейронные сети: BERT

- Глубокая (12 слоёв) архитектура на основе трансформера (механизма внимания).
- Преобразует последовательность индексов токенов в последовательность векторов.
- Дополнительный вектор для токена начала предложения (CLS-токен).

Нейронные сети: BERT

- Глубокая (12 слоёв) архитектура на основе трансформера (механизма внимания).
- Преобразует последовательность индексов токенов в последовательность векторов.
- Дополнительный вектор для токена начала предложения (CLS-токен).
- Предобучается на двух задачах:
  - Восстановлении пропущенного токена.
  - Проверке, идут ли два предложения друг за другом.

Нейронные сети: BERT

- Глубокая (12 слоёв) архитектура на основе трансформера (механизма внимания).
- Преобразует последовательность индексов токенов в последовательность векторов.
- Дополнительный вектор для токена начала предложения (CLS-токен).
- Предобучается на двух задачах:
  - Восстановлении пропущенного токена.
  - Проверке, идут ли два предложения друг за другом.
- Восстановление пропущенных слов – информация на уровне слов.
- Проверка следования предложений – задачи на уровне предложений / пар предложений.

Восстановление пропущенного токена

- Задача восстановления решается для 15% токенов.
  - 80% заменяются на специальный токен $\langle \text{MASK} \rangle$.
  - 10% на произвольное слово.
  - 10% остаются неизменными.
- Это эффективнее, чем предобучать модель слева направо.

BERT: входные данные

- Входное представление:

$$
\begin{aligned}
x_i &= x_i^{token} + x_i^{pos} + x_i^{type}, \\
x_i^{token} &- \text{эмбеддинг текущего токена}, \\
x_i^{pos} &- \text{эмбеддинг позиции } i, \\
x_i^{type} &- \text{эмбеддинг типа токена}.
\end{aligned}
$$

BERT: входные данные

- Входное представление:

$$
\begin{aligned}
x_i &= x_i^{token} + x_i^{pos} + x_i^{type}, \\
x_i^{token} &- \text{эмбеддинг текущего токена}, \\
x_i^{pos} &- \text{эмбеддинг позиции } i, \\
x_i^{type} &- \text{эмбеддинг типа токена.}
\end{aligned}
$$

- Тип токена – 0/1, нужно в задачах для пары предложений.
- Эмбеддинг позиции - i-ый элемент обучаемой матрицы $max\_length \times d_{hidden}$. Обычно $max\_length = 512, d_{hidden} = 768$.

BERT: токенизация

- BERT рассматривает слова на уровне BPE-токенов (Byte-Pair Encoding).
- BPE-словарь строится по следующим правилам:

BERT: токенизация

- BERT рассматривает слова на уровне BPE-токенов (Byte-Pair Encoding).
- BPE-словарь строится по следующим правилам:
- В начале элементы BPE-словаря – отдельные символы.
- На каждом шаге объединяется самая частая пара:

$$\begin{aligned} \mathrm{t} + \mathrm{h} &\mapsto \mathrm{th}, \\ \mathrm{i} + \mathrm{t} &\mapsto \mathrm{it}, \\ \ldots &\ldots \ldots, \\ \mathrm{th} + \mathrm{e} &\mapsto \mathrm{the}, \\ \ldots &\ldots \ldots \end{aligned}$$

BERT: токенизация

- BERT рассматривает слова на уровне BPE-токенов (Byte-Pair Encoding).
- BPE-словарь строится по следующим правилам:
- В начале элементы BPE-словаря – отдельные символы.
- На каждом шаге объединяется самая частая пара:

$$\begin{aligned} \mathrm{t} + \mathrm{h} &\mapsto \mathrm{th}, \\ \mathrm{i} + \mathrm{t} &\mapsto \mathrm{it}, \\ \ldots \quad \ldots &\quad \ldots, \\ \mathrm{th} + \mathrm{e} &\mapsto \mathrm{the}, \\ \ldots \quad \ldots &\quad \ldots \end{aligned}$$

- Так делается, пока не будет достигнут заранее заданный размер (~ 30000 в английской модели).

BERT: токенизация

- При токенизации BERT жадно пытается выделить самый длинный токен из словаря, начиная с конца слова.
- Так делается, пока не удастся дойти до начала слова.

BERT: токенизация

- При токенизации BERT жадно пытается выделить самый длинный токен из словаря, начиная с конца слова.
- Так делается, пока не удастся дойти до начала слова.
- При этом различаются токены в начале слова и не в начале:

$$\begin{aligned} \text{playing} &\to \text{play} + \#\#\text{ing}, \\ \text{replay} &\to \text{re} + \#\#\text{play}. \end{aligned}$$

- Наиболее частотные слова состоят из одного токена.

BERT: дообучение

- Задачи, на которых предобучается BERT, это классификация:
  - Языковое моделирование – классификация токенов.
  - Проверка следования – бинарная классификация CLS-токена.
- Непосредственно за классификацию отвечает верхний полносвязный слой с softmax-активацией.

BERT: дообучение

- Задачи, на которых предобучается BERT, это классификация:
  - Языковое моделирование – классификация токенов.
  - Проверка следования – бинарная классификация CLS-токена.
- Непосредственно за классификацию отвечает верхний полносвязный слой с softmax-активацией.
- Архитектура сети практически не изменится, если будет решаться другая задача:
  - Любая задача классификации предложений (или пар предложений).
  - Любая задача классификации отдельных слов.

BERT: дообучение

- При дообучении BERT на новую классификационную задачу заменяется только финальный слой:

$$\begin{aligned} \mathbf{p} &= \mathrm{softmax}(W\mathbf{h}), \\ W \in \mathbb{R}^{K*H} &- \text{обучаемая матрица}, \\ K &- \text{число классов}, \\ H &- \text{выходная размерность BERT (обычно 768)}. \end{aligned}$$

- Всего с нуля учится только несколько тысяч параметров (матрица W).

BERT: дообучение

- При дообучении BERT на новую классификационную задачу заменяется только финальный слой:

$$\begin{aligned} \mathbf{p} &= \mathrm{softmax}(W\mathbf{h}), \\ W \in \mathbb{R}^{K*H} &- \text{обучаемая матрица}, \\ K &- \text{число классов}, \\ H &- \text{выходная размерность BERT (обычно 768)}. \end{aligned}$$

- Всего с нуля учится только несколько тысяч параметров (матрица W).
- Это значительно меньше, чем основной энкодер BERT ($\sim 2 * 10^8$ параметров).
- Эта часть сети выучится гораздо быстрее и на небольшом количестве данных.
- При этом веса основной части сети тоже доучивают (обычно они изменятся не так сильно).

BERT: дообучение

- Одна из популярных задач, где BERT сильно улучшил качество – SQuAD:

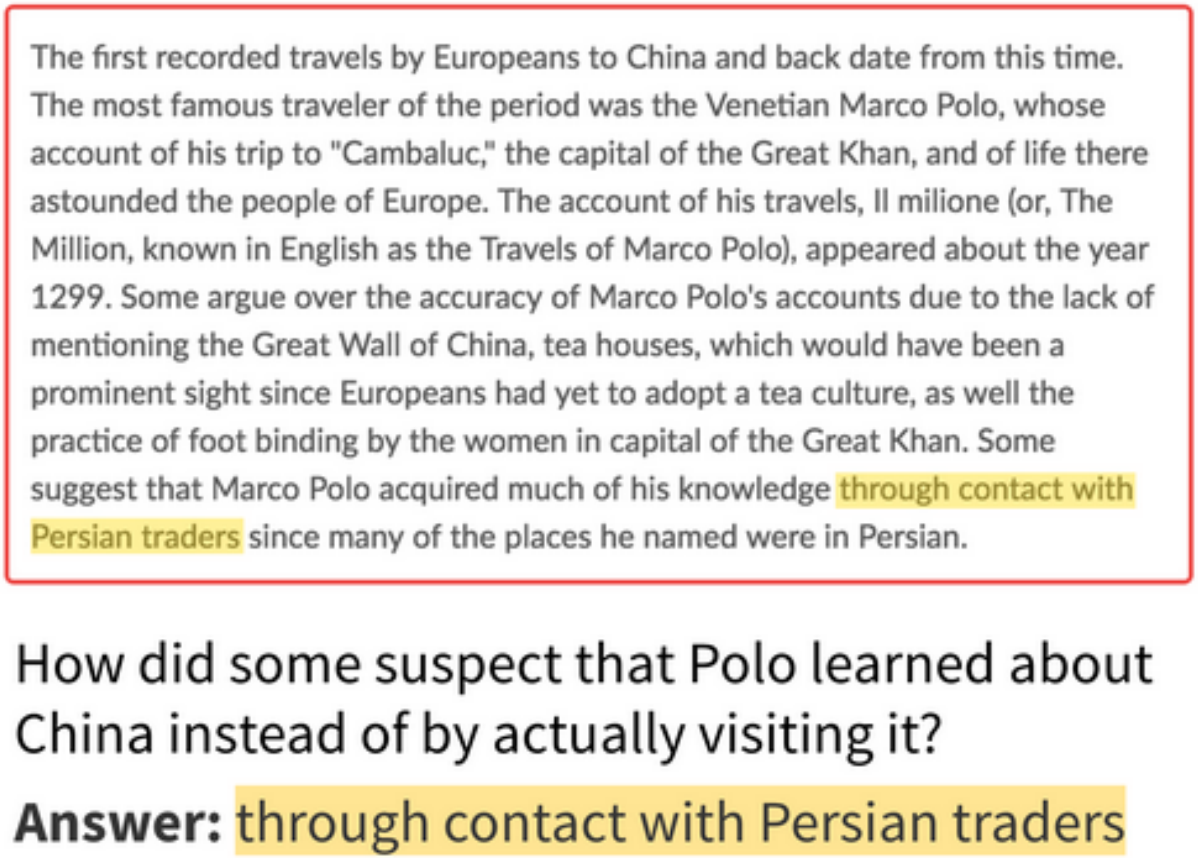

SQuAD: постановка задачи

- Одна из популярных задач, где BERT сильно улучшил качество – SQuAD.
- В ней требуется выделить в абзаце текста фрагмент, являющийся ответом на вопрос.
- Абзацы взяты из Википедии, вопросы составлены вручную.
- В SQuAD 2.0 появились вопросы, не содержащие ответа.

SQuAD: постановка задачи

- При составлении вопросов рекомендовалось использовать перефразировку, синонимы, гипонимы и гиперонимы:

Passage Segment

...The European Parliament and the Council of the European Union have powers of amendment and veto during the legislative process...

Question

Which governing bodies have veto power?

SQuAD: способы решения

- До появления BERT решали с помощью сопоставления между вопросом и контекстом.
- Например, с помощью разных вариантов внимания.
- Одна из архитектур – BiDAF (Bidirectional Attention Flow):

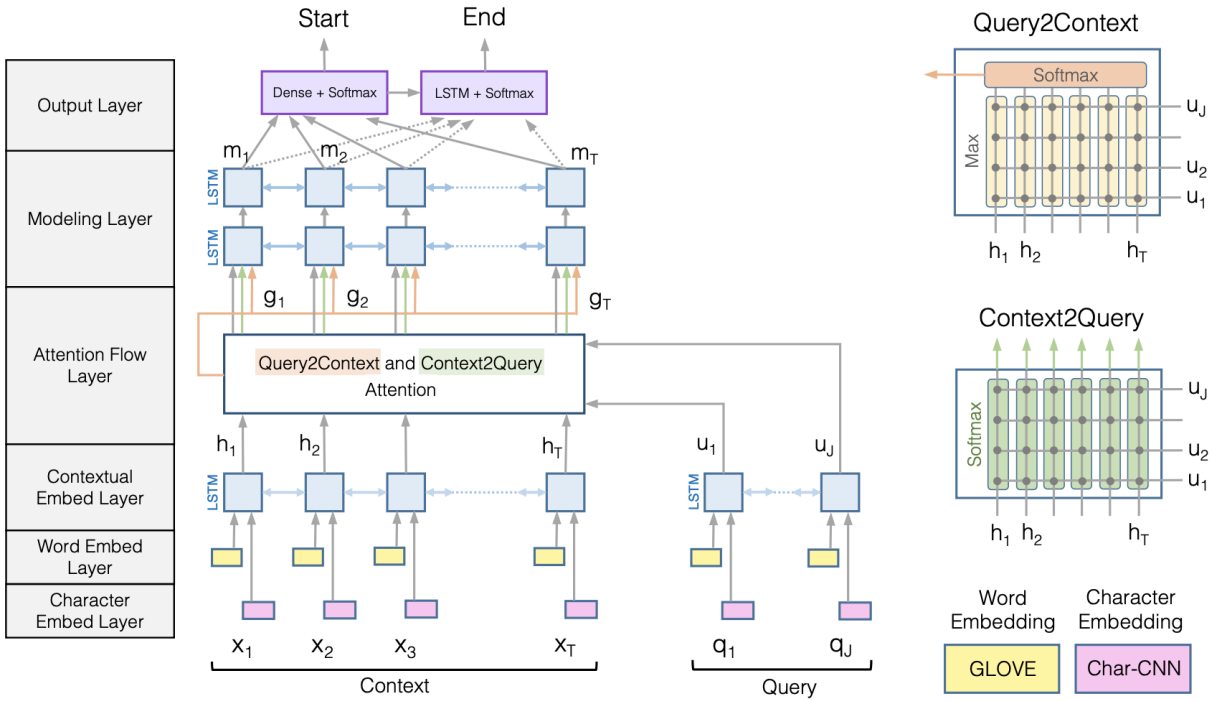

SQuAD: решение с помощью BERT

- Предсказываются позиции начала и конца фрагмента:

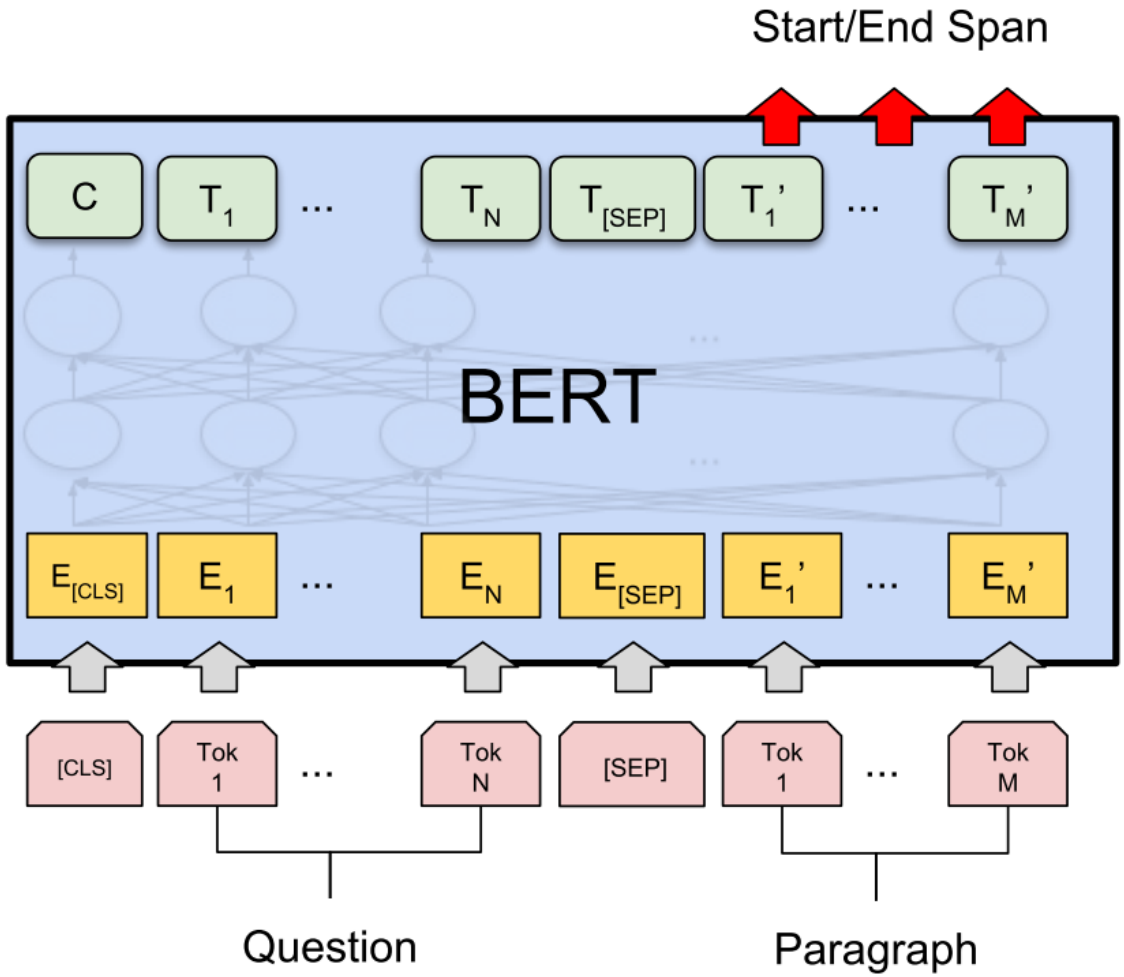

SQuAD: решение с помощью BERT

- Для каждой из границ ответ – распределение по токенам:

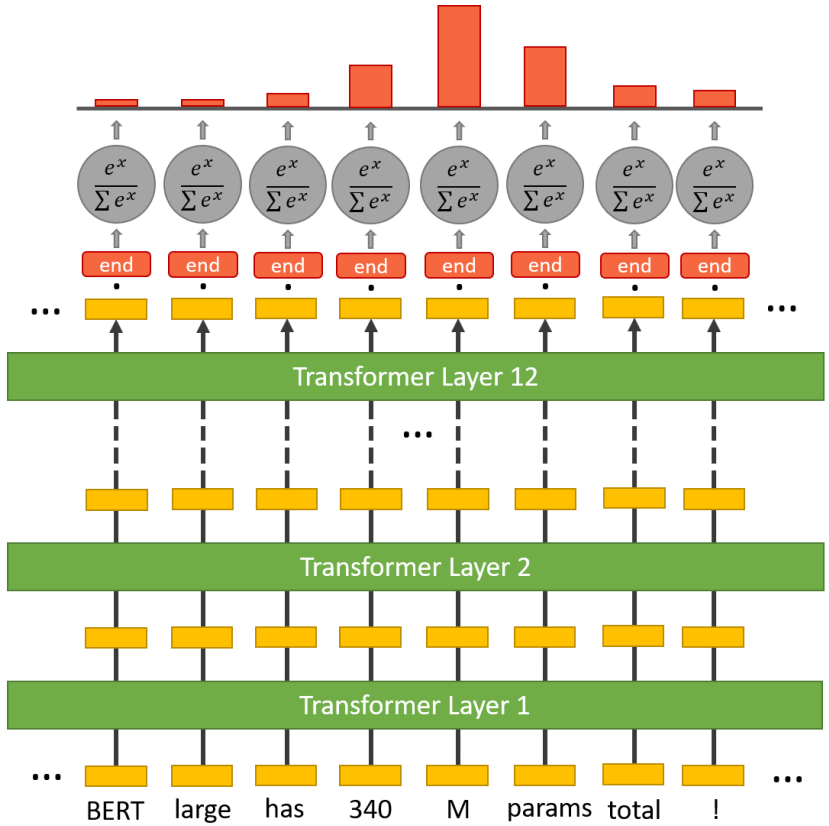

SQuAD: решение с помощью BERT

- Формальная архитектура (для позиции конца – аналогично):

$$
\begin{aligned}
[h_1, \ldots, h_n] &= \mathrm{BERT}([x_1, \ldots, x_n]), \\
a_i &= \langle w_S, x_i \rangle, \\
[p_1, \ldots, p_n] &= \mathrm{softmax}([a_1, \ldots, a_n]) \\
w_S &- \text{обучаемый вектор весов.}
\end{aligned}
$$

- Границы фрагмента выбираются как самая вероятная пара, где начало идёт раньше конца.

Мультиязычная BERT-модель

- Исходный BERT обучался на английской Википедии и корпусе художественной литературы.
- Мультиязычный BERT – на конкатенации 103 основных Википедий.
- Текст из более коротких Википедий сэмплировался с большим весом.

Мультиязычная BERT-модель

- Исходный BERT обучался на английской Википедии и корпусе художественной литературы.
- Мультиязычный BERT – на конкатенации 103 основных Википедий.
- Текст из более коротких Википедий сэмплировался с большим весом.
- Токенизация обучалась на тех же данных с тем же сэмплированием.
- В текст никак не включалась информация о языке.

Мультиязычная BERT-модель

- Исходный BERT обучался на английской Википедии и корпусе художественной литературы.
- Мультиязычный BERT – на конкатенации 103 основных Википедий.
- Текст из более коротких Википедий сэмплировался с большим весом.
- Токенизация обучалась на тех же данных с тем же сэмплированием.
- В текст никак не включалась информация о языке.
- Основное применение мультиязычной модели – настройка моделей для решения задач на конкретном языке.

Мультиязычная BERT-модель: недостатки

- Не все языки одинаково хорошо представлены в мультиязычной модели (точность языковой модели из Rönnquist et al., 2019):

	Mono	Multi
English	**45.92**	33.94
German	**43.93**	28.10
Swedish		22.30
Finnish		14.56
Danish		25.07
Norwegian (Bokmål)		25.21
Norwegian (Nynorsk)		22.28

Мультиязычная BERT-модель: недостатки

- Не все языки одинаково хорошо представлены в мультиязычной модели (точность языковой модели из Rönnquist et al., 2019):

	Mono	Multi
English	**45.92**	33.94
German	**43.93**	28.10
Swedish		22.30
Finnish		14.56
Danish		25.07
Norwegian (Bokmål)		25.21
Norwegian (Nynorsk)		22.28

- Токенизатор тоже может брать частотные фрагменты из другого языка:
  - године
  - року
  - було
  - ##лар.

Обучение BERT для языка

- BERT для любого языка можно было бы обучать так же, как английский.
- Однако обучение с нуля займёт много времени.
- С нуля надо обучать только BPE-токенизацию.

Обучение BERT для языка

- BERT для любого языка можно было бы обучать так же, как английский.
- Однако обучение с нуля займёт много времени.
- С нуля надо обучать только BPE-токенизацию.
- Можно инициализировать веса слоёв и эмбеддинги сабтокенов весами мультиязычной модели.
- Проблема в том, что набор токенов в словаре поменялся.

Обучение BERT для языка

- BERT для любого языка можно было бы обучать так же, как английский.
- Однако обучение с нуля займёт много времени.
- С нуля надо обучать только BPE-токенизацию.
- Можно инициализировать веса слоёв и эмбеддинги сабтокенов весами мультиязычной модели.
- Проблема в том, что набор токенов в словаре поменялся.
- Решение: эмбеддинг токена инициализируется усреднением его мультиязычных эмбеддингов.

Обучение BERT для русского языка

- За счёт инициализации обучение существенно ускоряется (Kuratov and Arkhipov, 2019):

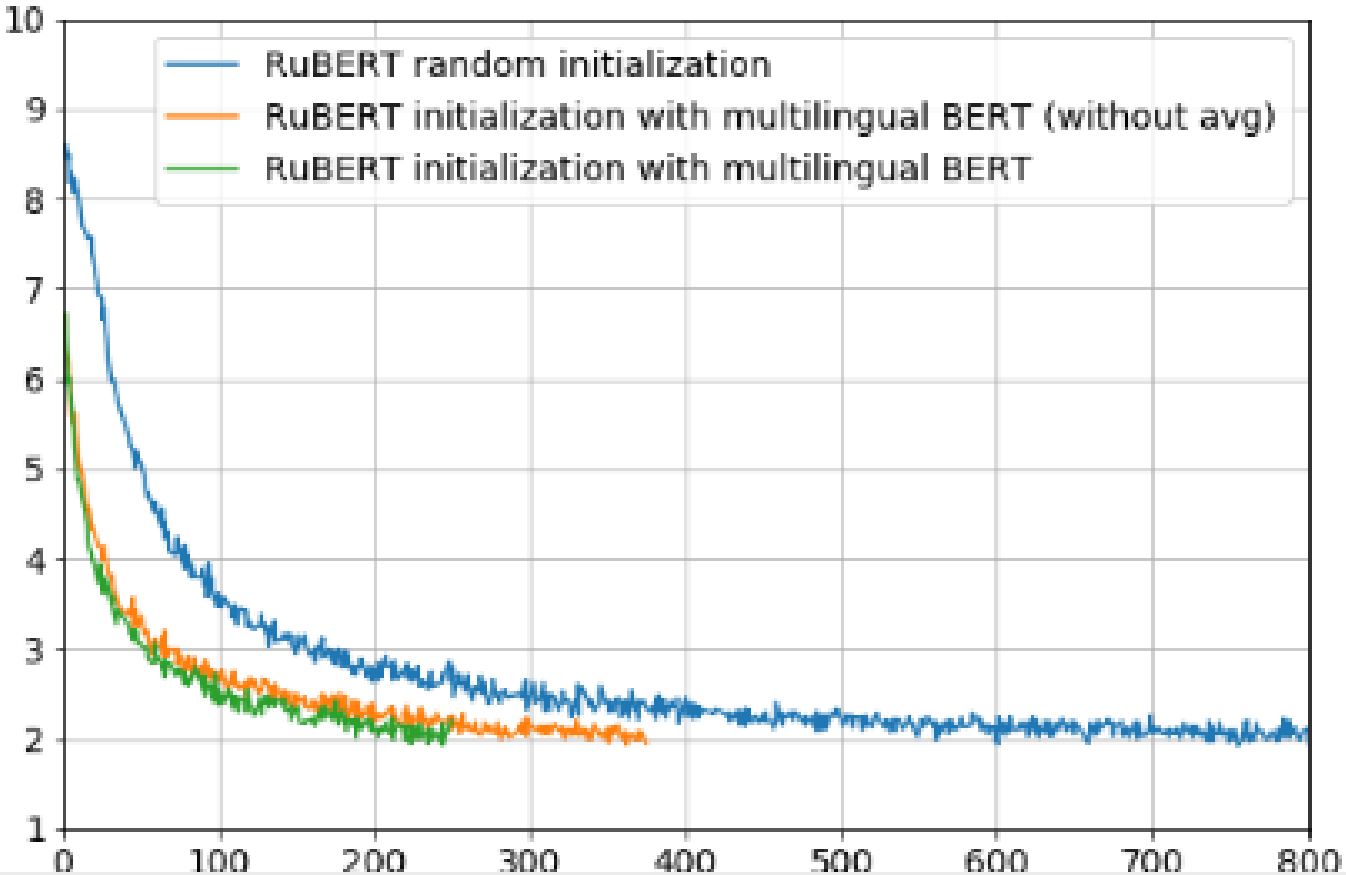

Обучение BERT для русского языка

- Улучшается качество на парафразе и ответах на вопросы:

model	F-1	Accuracy
Neural networks [11]	79.82	76.65
Classifier + linguistic features [11]	81.10	77.39
Machine Translation + Semantic similarity [6]	78.51	81.41
BERT multilingual	85.48 ± 0.19	81.66 ± 0.38
RuBERT	$\mathbf{87.73} \pm 0.26$	$\mathbf{84.99} \pm 0.35$

Table 1: ParaPhraser. We compare BERT based models with models in non-standard run setting, when all resources were allowed.

model	F-1 (dev)	EM (dev)
R-Net from DeepPavlov [2]	80.04	60.62
BERT multilingual	83.39 ± 0.08	64.35 ± 0.39
RuBERT	$\mathbf{84.60} \pm 0.11$	$\mathbf{66.30} \pm 0.24$

Обучение BERT для нескольких языков

- Можно обучать BERT и для нескольких родственных языков одновременно:

Model	Span F_1	RPM	REM	SM
Bi-LSTM-CRF (Lample et al., 2016)	75.8	73.9	72.1	72.3
Multilingual BERT [5]	79.6	77.8	76.1	77.2
Multilingual BERT-CRF	81.4	80.9	79.2	79.6
Slavic BERT	83.5	83.8	82.0	82.2
Slavic BERT-CRF	87.9	85.7 (90.9)	84.3 (86.4)	84.1 (85.7)

Table 1: Metrics for BSNLP on validation set (Asia Bibi documents). Metrics on the test set are in the brackets.

Обучение BERT для нескольких языков

- Побочный недостаток дообучения BERT: падает качество на родственных языках (пример для задачи морфосинтаксического анализа, Sorokin, 2019)

Training data	BERT	Tag	Tag sent	LAS	Sent LAS	UAS	Sent UAS
be	multlingual	85,09	10,29	76,34	14,71	83,72	17,65
be	Russian	80,75	4,41	45,66	1,47	57,45	4,41
be+ru+uk	multlingual	**88,57**	**19,12**	**84,8**	**16,18**	**90,74**	**33,82**
be+ru+uk	Russian	83,79	7,35	59,3	1,47	68,74	4,41

- То есть модель очень сильно переобучается под конкретный язык.

Набор GLUE

Corpus	|Train|	|Test|	Task	Metrics	Domain
			Single-Sentence Tasks		
CoLA	8.5k	**1k**	acceptability	Matthews corr.	misc.
SST-2	67k	1.8k	sentiment	acc.	movie reviews
			Similarity and Paraphrase Tasks		
MRPC	3.7k	1.7k	paraphrase	acc./F1	news
STS-B	7k	1.4k	sentence similarity	Pearson/Spearman corr.	misc.
QQP	364k	**391k**	paraphrase	acc./F1	social QA questions
			Inference Tasks		
MNLI	393k	**20k**	NLI	matched acc./mismatched acc.	misc.
QNLI	105k	5.4k	QA/NLI	acc.	Wikipedia
RTE	2.5k	3k	NLI	acc.	news, Wikipedia
WNLI	634	**146**	coreference/NLI	acc.	fiction books

Table 1: Task descriptions and statistics. All tasks are single sentence or sentence pair classification, except STS-B, which is a regression task. MNLI has three classes; all other classification tasks have two. Test sets shown in bold use labels that have never been made public in any form.

Набор GLUE

- Довольно быстро на GLUE было превышено качество, достигаемое человеком:

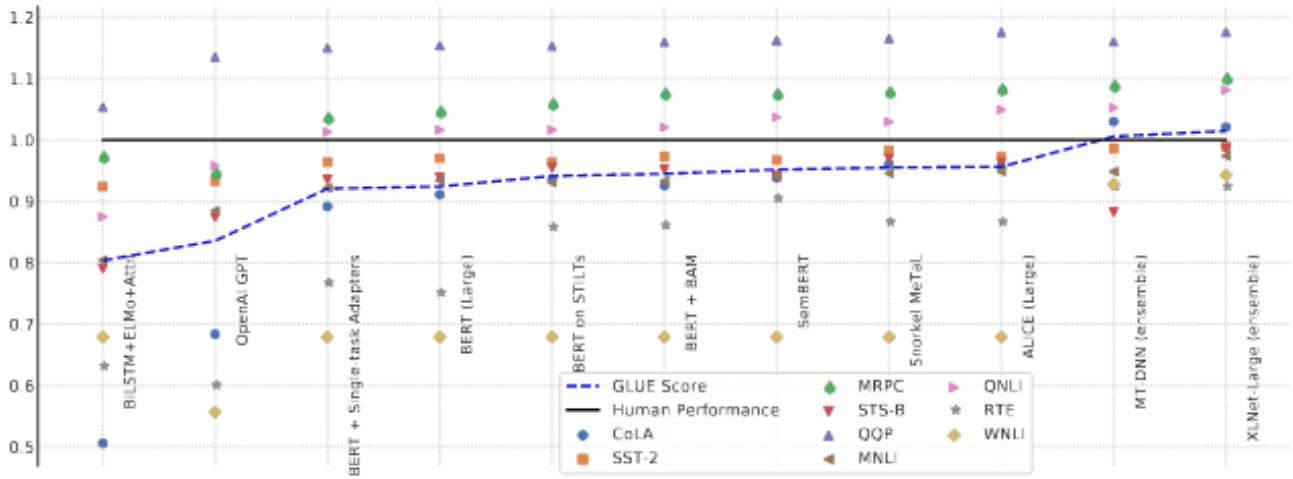

SuperGLUE

- Новый набор – SuperGLUE:

Table 1: The tasks included in SuperGLUE. *WSD* stands for word sense disambiguation, *NLI* is natural language inference, *coref.* is coreference resolution, and *QA* is question answering. For MultiRC, we list the number of total answers for 456/83/166 train/dev/test questions.

Corpus	|Train|	|Dev|	|Test|	Task	Metrics	Text Sources
BoolQ	9427	3270	3245	QA	acc.	Google queries, Wikipedia
CB	250	57	250	NLI	acc./F1	various
COPA	400	100	500	QA	acc.	blogs, photography encyclopedia
MultiRC	5100	953	1800	QA	$F1_a$/EM	various
ReCoRD	101k	10k	10k	QA	F1/EM	news (CNN, Daily Mail)
RTE	2500	278	300	NLI	acc.	news, Wikipedia
WiC	6000	638	1400	WSD	acc.	WordNet, VerbNet, Wiktionary
WSC	554	104	146	coref.	acc.	fiction books

SuperGLUE

- Новый набор – SuperGLUE:

BoolQ	**Passage:** *Barq's – Barq's is an American soft drink. Its brand of root beer is notable for having caffeine. Barq's, created by Edward Barq and bottled since the turn of the 20th century, is owned by the Barq family but bottled by the Coca-Cola Company. It was known as Barq's Famous Olde Tyme Root Beer until 2012.* **Question:** *is barq's root beer a pepsi product* **Answer:** `No`
CB	**Text:** *B: And yet, uh, I we-, I hope to see employer based, you know, helping out. You know, child, uh, care centers at the place of employment and things like that, that will help out. A: Uh-huh. B: What do you think, do you think we are, setting a trend?* **Hypothesis:** *they are setting a trend* **Entailment:** `Unknown`
COPA	**Premise:** *My body cast a shadow over the grass.* **Question:** *What's the CAUSE for this?* **Alternative 1:** *The sun was rising.* **Alternative 2:** *The grass was cut.* **Correct Alternative:** `1`

SuperGLUE

- Новый набор – SuperGLUE:

MultiRC

Paragraph: *Susan wanted to have a birthday party. She called all of her friends. She has five friends. Her mom said that Susan can invite them all to the party. Her first friend could not go to the party because she was sick. Her second friend was going out of town. Her third friend was not so sure if her parents would let her. The fourth friend said maybe. The fifth friend could go to the party for sure. Susan was a little sad. On the day of the party, all five friends showed up. Each friend had a present for Susan. Susan was happy and sent each friend a thank you card the next week*
Question: *Did Susan's sick friend recover?* **Candidate answers:** *Yes, she recovered* (T), *No* (F), *Yes* (T), *No, she didn't recover* (F), *Yes, she was at Susan's party* (T)

ReCoRD

Paragraph: *(CNN) Puerto Rico on Sunday overwhelmingly voted for statehood. But Congress, the only body that can approve new states, will ultimately decide whether the status of the US commonwealth changes. Ninety-seven percent of the votes in the nonbinding referendum favored statehood, an increase over the results of a 2012 referendum, official results from the State Electorcal Commission show. It was the fifth such vote on statehood. "Today, we the people of Puerto Rico are sending a strong and clear message to the US Congress ... and to the world ... claiming our equal rights as American citizens, Puerto Rico Gov. Ricardo Rossello said in a news release. @highlight Puerto Rico voted Sunday in favor of US statehood*
Query For one, they can truthfully say, "Don't blame me, I didn't vote for them, " when discussing the <placeholder> presidency **Correct Entities:** US

SuperGLUE

- Новый набор – SuperGLUE:

RTE	**Text:** *Dana Reeve, the widow of the actor Christopher Reeve, has died of lung cancer at age 44, according to the Christopher Reeve Foundation.* **Hypothesis:** *Christopher Reeve had an accident.* **Entailment:** `False`
WiC	**Context 1:** *Room and board.* **Context 2:** *He nailed boards across the windows.* **Sense match:** `False`
WSC	**Text:** *Mark told Pete many lies about himself, which Pete included in his book. He should have been more truthful.* **Coreference:** `False`

SuperGLUE

- BERT – базовое решение для SuperGLUE:
- Классификация пары предложений:
  - BoolQ, CB, RTE, WiC.
  - Логистическая регрессия на 2 класса для CLS-вектора.

SuperGLUE

- BERT – базовое решение для SuperGLUE:
- Классификация пары предложений:
  - BoolQ, CB, RTE, WiC.
  - Логистическая регрессия на 2 класса для CLS-вектора.
- Выбор варианта:
  - COPA, MultiRC, ReCoRD.
  - Для каждого варианта считается CLS-вектор:

$$h_i = \mathrm{Encoder}([\mathrm{Context}, \mathrm{Variant}_i])[0]$$

SuperGLUE

- BERT – базовое решение для SuperGLUE:
- Классификация пары предложений:
  - BoolQ, CB, RTE, WiC.
  - Логистическая регрессия на 2 класса для CLS-вектора.
- Выбор варианта:
  - COPA, MultiRC, ReCoRD.
  - Для каждого варианта считается CLS-вектор:

$$h_i = \mathrm{Encoder}([\mathrm{Context}, \mathrm{Variant}_i])[0]$$

  - Эти представления пропускаются через дополнительную сеть:

$$s_i = \sigma(\langle w, h_i \rangle)$$

SuperGLUE

- BERT – базовое решение для SuperGLUE:
- Классификация пары предложений:
  - BoolQ, CB, RTE, WiC.
  - Логистическая регрессия на 2 класса для CLS-вектора.
- Выбор варианта:
  - COPA, MultiRC, ReCoRD.
  - Для каждого варианта считается CLS-вектор:

$$h_i = \mathrm{Encoder}([\mathrm{Context}, \mathrm{Variant}_i])[0]$$

  - Эти представления пропускаются через дополнительную сеть:

$$s_i = \sigma(\langle w, h_i \rangle)$$

  - Далее классификатор выбирает самую большую s_i:

$$[p_1, \ldots, p_K] = \mathrm{softmax}([s_1, \ldots, s_k])$$

  - В случае нескольких правильных ответов – логистическая регрессия применяется к каждому h_i.

Другие данные для тестирования

- SQuAD1.1 / SQuAD 2.0 – нахождение ответа в тексте.
- MNLI – проверка логического следования.
- SST-2 (Stanford Sentiment Treebank) – анализ тональности.
- RACE – понимание текста (выбор верного варианта ответа на вопрос).
- STS-B (Semantic Textual Similarity) – проверка схожести текстов.
- CNN/Daily Mail Corpus – автоматическое реферирование (для новостных текстов).
- WMT – машинный перевод, особенно часто
  - En-De, De-En, En-Fr, Fr-En.
  - En-Ro, Ro-En – для малоресурсного тестирования.

RussianSuperGLUE

DaNetQA

Passage: *В период с 1969 по 1972 год по программе «Аполлон» было выполнено 6 полётов с посадкой на Луне.*
Question: *Был ли человек на луне?*
Answer: Yes

PARus

Premise: *Гости вечеринки прятались за диваном.*
Question: *Почему это произошло?*
Alternative 1: *Это была вечеринка-сюрприз.*
Alternative 2: *Это был день рождения.*
Correct Alternative: 1

RussianSuperGLUE

RUSSE

Context 1: *Бурые ковровые дорожки заглушали шаги.* **Context 2:** *Приятели решили выпить на дорожку в местном баре.*
Sense match: False

TERRA

Text: *Автор поста написал в комментарии, что прорвалась канализация.*
Hypothesis: *Автор поста написал про канализацию.* **Entailment:** True

Бенчмарки для русского языка: SuperGLUE

- TERRa – проверка логического следования (аналог RTE),
- DaNetQA – ответ на да/нет-вопрос (аналог BoolQ),
- PaRUS – выбор правильного продолжения предложения (аналог COPA)

Бенчмарки для русского языка: SuperGLUE

- TERRa – проверка логического следования (аналог RTE),
- DaNetQA – ответ на да/нет-вопрос (аналог BoolQ),
- PaRUS – выбор правильного продолжения предложения (аналог COPA)
- Другие аналоги задач из SuperGLUE.
- Задачи не из SuperGLUE:
  - Распознавание именованных сущностей – Collection5,
  - Поиск ответа в тексте – SberQUAD
- Чаще всего качество данных хуже соответствующих английских задач.

Roberta

- Roberta – модификация BERT, отличающаяся:
  - Динамическим маскированием.
  - Отсутствием задачи проверки следования предложений друг за другом.
  - Большим размером батча при обучении.
  - Способом объединения предложений в батчи.

Roberta

- Roberta – модификация BERT, отличающаяся:
  - Динамическим маскированием.
  - Отсутствием задачи проверки следования предложений друг за другом.
  - Большим размером батча при обучении.
  - Способом объединения предложений в батчи.
- Также были изменены обучающий корпус и число шагов при обучении.
- Были изменены некоторые параметры оптимизатора и генерации обучающих данных.
- Словарь модели составлен на уровне байтов и расширен до 50000.

Roberta

Model	data	bsz	steps	SQuAD (v1.1/2.0)	MNLI-m	SST-2
RoBERTa						
with BOOKS + WIKI	16GB	8K	100K	93.6/87.3	89.0	95.3
+ additional data (§3.2)	160GB	8K	100K	94.0/87.7	89.3	95.6
+ pretrain longer	160GB	8K	300K	94.4/88.7	90.0	96.1
+ pretrain even longer	160GB	8K	500K	**94.6/89.4**	**90.2**	**96.4**
$\text{BERT}_{\text{LARGE}}$						
with BOOKS + WIKI	13GB	256	1M	90.9/81.8	86.6	93.7
$\text{XLNet}_{\text{LARGE}}$						
with BOOKS + WIKI	13GB	256	1M	94.0/87.8	88.4	94.4
+ additional data	126GB	2K	500K	94.5/88.8	89.8	95.6

AlBERT

AlBERT – модификация BERT, отличающаяся:

- Общие параметры у всех слоёв Трансформера.

AlBERT

AlBERT – модификация BERT, отличающаяся:

- Общие параметры у всех слоёв Трансформера.
- Двухступенчатое вычисление эмбеддингов (позволяет уменьшить число параметров):

$$\begin{aligned} \widetilde{e}_i &= V_1[0, \ldots, 1, \ldots, 0], \\ e_i &= V_2 \widetilde{e}_i \end{aligned}$$

AlBERT

AlBERT – модификация BERT, отличающаяся:

- Общие параметры у всех слоёв Трансформера.
- Двухступенчатое вычисление эмбеддингов (позволяет уменьшить число параметров):

$$\begin{aligned} \widetilde{e}_i &= V_1[0,\ldots,1,\ldots,0], \\ e_i &= V_2\widetilde{e}_i \end{aligned}$$

- Замена задачи проверки следования на распознавание порядка следования (в каком порядке идут два предложения в документе).

AlBERT: результаты

- Можно увеличить размер эмбеддингов:

Model		Parameters	Layers	Hidden	Embedding	Parameter-sharing
BERT	base	108M	12	768	768	False
	large	334M	24	1024	1024	False
ALBERT	base	12M	12	768	128	True
	large	18M	24	1024	128	True
	xlarge	60M	24	2048	128	True
	xxlarge	235M	12	4096	128	True

- Это приводит к росту результатов.

Model		Parameters	SQuAD1.1	SQuAD2.0	MNLI	SST-2	RACE	Avg	Speedup
BERT	base	108M	90.4/83.2	80.4/77.6	84.5	92.8	68.2	82.3	4.7x
	large	334M	92.2/85.5	85.0/82.2	86.6	93.0	73.9	85.2	1.0
ALBERT	base	12M	89.3/82.3	80.0/77.1	81.6	90.3	64.0	80.1	5.6x
	large	18M	90.6/83.9	82.3/79.4	83.5	91.7	68.5	82.4	1.7x
	xlarge	60M	92.5/86.1	86.1/83.1	86.4	92.4	74.8	85.5	0.6x
	xxlarge	235M	**94.1/88.3**	**88.1/85.1**	**88.0**	**95.2**	**82.3**	**88.7**	0.3x

AlBERT: результаты

- Задача проверки порядка предложений оказывается более удачной для предобучения:

	Intrinsic Tasks			Downstream Tasks					
SP tasks	MLM	NSP	SOP	SQuAD1.1	SQuAD2.0	MNLI	SST-2	RACE	Avg
None	54.9	52.4	53.3	88.6/81.5	78.1/75.3	81.5	89.9	61.7	79.0
NSP	54.5	90.5	52.0	88.4/81.5	77.2/74.6	81.6	**91.1**	62.3	79.2
SOP	54.0	78.9	86.5	**89.3/82.3**	**80.0/77.1**	**82.0**	90.3	**64.0**	**80.1**

- При этом исходный BERT не умеет её решать.